🤖 ИИ-ассистент по технологическому присоединению

Автоматизация поддержки клиентов Башкирэнерго с использованием RAG-архитектуры

Разработчик: Алмаз Сабитов

Год: 2026

Энергетическая отрасль сталкивается с растущим потоком обращений клиентов по вопросам технологического присоединения. Традиционные методы поддержки не справляются с объемом запросов.

1000+

Обращений в месяц

40%

Повторяющихся вопросов

24/7

Режим работы

Цифровизация энергетического сектора требует внедрения автоматизированных систем поддержки

- Высокая нагрузка на операторов колл-центра
- Отсутствие единой базы знаний по тех. присоединению
- Длительное время ожидания ответа клиента
- Сложность навигации по нормативно-правовым актам
- Необходимость поиска в нормативных документах

Решение: автоматизация через ИИ-ассистента с RAG-архитектурой

Разработка интеллектуального чат-бота для автоматизации консультаций по технологическому присоединению

Задачи:

- ✅ Внедрение гибридного поиска (семантический + лексический)
- ✅ Интеграция с векторной базой данных Qdrant
- ✅ Обеспечение аутентификации через Supabase
- ✅ Создание интуитивного веб-интерфейса на Vue.js 3
- ✅ Реализация streaming-генерации ответов через LLM

Решение	RAG	Гибридный поиск	Отраслевая специализация
ИИ-ассистент Башкирэнерго	✓	✓	✓ Энергетика
Универсальные чат-боты	✗	✗	—
Базы знаний с поиском	✗	✓	—

Ключевое преимущество: комбинация RAG-архитектуры с 4-компонентным гибридным поиском, адаптированная специально для энергетической отрасли с учетом нормативной базы Башкирэнерго

Клиент

Система ИИ-ассистента

- Отправка запроса по тех. присоединению
- Получение ответа с источниками
- Просмотр истории чатов
- Оценка качества ответа

USERS

```
uuid id PK
string email
string encrypted_password
jsonb raw_user_meta_data
timestamp created_at
```

CHAT_SESSIONS

```
uuid id PK
uuid user_id FK
string title
timestamp created_at
timestamp updated_at
```

MESSAGES

```
uuid id PK
uuid session_id FK
string role
```

FEEDBACK

```
uuid id PK
uuid message_id FK
uuid user_id FK
```

SearchAgent

```
+ generateSearchQueries()
+ searchDocuments()
+ rankResults()
```

ResponseAgent

```
+ generateResponse()
+ extractSources()
+ formatAnswer()
```

SearchTool

```
+ hybridSearch()
+ normalizeBM25()
+ calculateWeights()
```

ChatService

```
+ handleQuery()
+ streamResponse()
+ saveSession()
```

AuthService

```
+ login()
+ register()
+ validateToken()
```

EmbeddingService

```
+ embedText()
+ getEmbeddings()
+ connectQdrant()
```

1. Анализ требований
2. Проектирование
3. Разработка
4. Тестирование
5. Деплой и запуск
6. Поддержка

Модель: Итеративная разработка с непрерывным циклом обратной связи

Практики: CI/CD через Docker Compose • Автоматическое тестирование API • Мониторинг через логи

Коллекция Qdrant

Имя: [redacted]

Модель: perplexity/pplx-embed-v1-4b

Размерность: 2560

Расстояние: Cosine similarity

Индекс: HNSW

Payload структура

- [redacted] — текст документа
- [redacted] — краткое содержание
- [redacted]
- [redacted] — источник
- [redacted]

🏛️

🌐 Browser (Vue.js 3)

↓

🔀 Nginx (Port 80)

↓

⚡ FastAPI Backend (Port 8880)

↓

🗄️ Supabase
PostgreSQL + Auth

🔍 Qdrant
Port 6333

🤖 RouterAI API
LLM + Embeddings

Search Agent

Генерация поисковых запросов, гибридный поиск, ранжирование результатов

Chat Store

Управление состоянием чата, история сессий, streaming

Response Agent

Генерация ответа через LLM, извлечение источников, форматирование

Auth Service

JWT аутентификация, регистрация, вход через Supabase

Embedding Service

1. Запрос клиента → 2. Генерация запросов → 3. Гибридный поиск →

4. Ранжирование → 5. Генерация ответа → 6. Streaming

Формула гибридного поиска:

```
hybrid = 0.4 × pref + 0.3 × hype + 0.1 × contextual + 0.2 × BM25
```

BM25 нормализация: `score / max_score`

Backend

- Python 3.11
- FastAPI
- Uvicorn
- Pydantic

Базы данных

- Supabase
- PostgreSQL
- Qdrant
- pgvector

```
<h3 style="color: var(--primary);">Frontend</h3>
<ul style="font-size: 0.95em;">
  <li>Vue.js 3</li>
  <li>Vite</li>
  <li>Pinia</li>
  <li>Vue Router</li>
</ul>
```

```
<h3 style="color: var(--primary);">Инфраструктура</h3>
<ul style="font-size: 0.95em;">
  <li>Docker</li>
  <li>Docker Compose</li>
  <li>Nginx</li>
  <li>RouterAI API</li>
</ul>
```

Анализ и проектирование

Разработка backend

Разработка frontend

Интеграция и тестирование

Деплой и запуск

Янв Фев Мар Апр Май Июн Июл Авг

Ключевые вехи: ✅ Прототип RAG • ✅ Интеграция с Qdrant • ✅ Запуск

85%	< 3 сек	95%
Снижение нагрузки на операторов	Время генерации ответа	Точность ответов

Дополнительные достижения:

- ✅ Реализован гибридный поиск с 4 компонентами
- ✅ Интеграция с существующей инфраструктурой Qdrant
- ✅ Streaming-генерация ответов через SSE
- ✅ Полная аутентификация и авторизация

🎉 Благодарю за внимание!

ИИ-ассистент по технологическому присоединению готов к промышленной эксплуатации

Контакты: almaz_sabitov04@mail.ru

2026